

Dataframes métodos usuales

agg Devuelve un data frame con una única fila con varias columnas con valores que provienen de funciones de agregación tales como: **avg, count, first, last, max, mean, min, sum, sumDistinct**

columns Atributo que devuelve una lista con los nombres de las columnas

count Devuelve el numero de filas del DataFrame

distinct Retorna un nuevo DataFrame que contiene las filas que son distintas

dtypes un atributo que devuelve el nombre y tipo de dato de cada columna

drop(col) Devuelve un nuevo del que se ha eliminado la columna col

dropDuplicates Retorna un nuevo DataFrame del que se han eliminado filas duplicadas. A diferencia **distinct** se puede especificar las columnas que se usarán para comprobar la duplicidad. `df.dropDuplicates(Array("a", "b"))`

na Para el manejo de valores nulos. Se puede eliminar, llenar o reemplazar valores nulos
drop elimina

fill Llena los nulos con un valor específico
replace Reemplaza nulos con un valor de una columna específica

filter o **where** Filtra las filas que cumplen una condición dada

groupBy Agrupa las filas del DataFrame por una o más columnas. Sobre el dataframe resultante se puede realizar funciones de agregación (**avg**, **min**, **max**, **sum**, ...)

intersect
union
unionAll Devuelven un dataframe con la intersección y unión, es decir, **intersect** devuelve un nuevo dataframe con las filas comunes entre dos dataframes.

unionByName **union** devuelve todas las filas de ambos dataframes, sin eliminar duplicados.
unionAll igual a **union**.
unionByName une 2 dataframes por el nombre en lugar de la posición.

limit Limita el resultado a n filas

orderBy Ordena el dataframe según una o más columnas

select Selecciona columnas específicas del dataframe

selectExpr

Útil para realizar selecciones complejas y transformaciones en un dataframe usando sintaxis familiar de SQL

```
df.selectExpr("a * 2", "b < 10 as M")
```

withColumn

Se usa para crear una nueva columna o reemplazar una existente
Se puede usar para aplicar transformaciones o agregar columnas derivadas de otras

withColumnRenamed

Se usa para cambiar el nombre de una columna existente

join

Permite unir filas de dos dataframes basándose en una condición específica

Inner Join

filas que coinciden en ambos dataframes

Left outer Join

todas las filas del df izq. y las coincidencias del de dere.

Right outer Join

todas las filas del df dere. y las coincidencias del de la izq.

Full outer Join

todas las filas cuando hay una coincidencia en uno de los df

Cross Join

Devuelve el producto cartesiano de los 2 df.

by: jorgaf
@jorgaf